

# LAPORAN KESEHATAN STATISTIK

## Statistical Audit of Open-Source Project

pandas-dev/pandas

|                 |                                                  |
|-----------------|--------------------------------------------------|
| Mata Kuliah     | Statistika & Probabilitas                        |
| Proyek Diaudit  | pandas-dev/pandas (github.com/pandas-dev/pandas) |
| Periode Data    | 2017 – 2024                                      |
| Tanggal Laporan | 10 Juni 2026                                     |

### Tim Penyusun

| No | Nama             | NIM        | Peran                                        |
|----|------------------|------------|----------------------------------------------|
| 1  | Soko Selowansyah | 1519625063 | Team Leader & Data Collection                |
| 2  | Anggota 2        | —          | Exploratory Data Analysis (EDA)              |
| 3  | Anggota 3        | —          | Parameter Estimation & Confidence Interval   |
| 4  | Anggota 4        | —          | Hypothesis Testing                           |
| 5  | Anggota 5        | —          | Simulation (Monte Carlo, Bloom Filter, MCMC) |

Universitas Negeri Jakarta . STI 2025. Juni 2026

Link Github : [github.com/sokoselowansyah20-hue/stat-audit-pandas-sti-2025](https://github.com/sokoselowansyah20-hue/stat-audit-pandas-sti-2025)

## 1. Ringkasan Eksekutif (Executive Summary)

statistik ini menganalisis kesehatan repositori open-source **pandas-dev/pandas** melalui empat lapisan analisis: eksplorasi data, estimasi parameter, pengujian hipotesis, dan komputasi probabilistik. Berikut adalah temuan utama yang dapat ditindaklanjuti oleh para maintainer:

|   |                                                                                                                                                                                                                                                                                                                        |
|---|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1 | <b>Tingkat Penggabungan PR (~62%):</b> Estimasi MLE Bernoulli menunjukkan probabilitas sebuah pull request diterima adalah sekitar 0,62. Meskipun menunjukkan kurasi aktif, terdapat peningkatan PR yang ditolak pada periode pasca-rilis major — maintainer disarankan memperbarui panduan kontribusi secara berkala. |
| 2 | <b>Laju Laporan Bug Poisson (<math>\lambda \approx 3\text{--}5</math> issue/hari):</b> Uji hipotesis menunjukkan tidak ada perubahan signifikan dalam laju laporan bug setelah rilis 2.0, mengindikasikan transisi versi berjalan relatif mulus dibanding rilis major sebelumnya.                                      |
| 3 | <b>Probabilitas Issue &gt;30 Hari (~30%):</b> Simulasi Monte Carlo ( $n=50.000$ ) memperkirakan ~30% issue memerlukan lebih dari 30 hari untuk diselesaikan — menunjukkan kebutuhan triase lebih aktif untuk issue berlabel "enhancement" atau "API design".                                                           |
| 4 | <b>Bloom Filter Efektif untuk Deteksi Kontributor Duplikat:</b> Dengan konfigurasi $k=5$ , $m=10n$ , FPR teoritis di bawah 0,01% — layak diimplementasikan pada pipeline pengecekan kontributor baru secara real-time.                                                                                                 |
| 5 | <b>Rekomendasi Sprint via MCMC:</b> Optimisasi MCMC Knapsack mengidentifikasi subset issue dengan rasio nilai/bobot tertinggi, memberikan dasar kuantitatif untuk perencanaan sprint maintainer.                                                                                                                       |

## 2. Ikhtisar Data (Data Overview)

Data dikumpulkan dari GitHub REST API pada periode **Januari 2017 – Desember 2024**. Pengumpulan dilakukan oleh Member A (Data Engineer) menggunakan pagination otomatis dengan penanganan rate-limit. Data mentah disimpan di `data/raw/` dan tidak pernah dimodifikasi; versi bersih tersedia di `data/clean/dataset.csv`.

| Atribut                     | Nilai                                                                                                                                         |
|-----------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| URL Repositori              | <a href="https://github.com/pandas-dev/pandas">https://github.com/pandas-dev/pandas</a>                                                       |
| Rentang Waktu               | Januari 2017 – Desember 2024 (≈8 tahun)                                                                                                       |
| Total Issue (closed)        | > 20.000 issue                                                                                                                                |
| Total Pull Request (merged) | > 8.000 PR                                                                                                                                    |
| Total Kontributor Unik      | > 3.000 akun                                                                                                                                  |
| Kolom Utama                 | <code>created_at</code> , <code>closed_at</code> , <code>state</code> , <code>user_login</code> , <code>comments</code> , <code>labels</code> |
| Format File                 | CSV, UTF-8, koma sebagai delimiter                                                                                                            |
| Tanggal Koleksi             | 10 Juni 2026                                                                                                                                  |

### Keterbatasan Data yang Diketahui

- GitHub API membatasi 5.000 request/jam; beberapa PR lama mungkin tidak terkumpul jika terjadi timeout saat koleksi.
- Issue yang dikonversi menjadi diskusi (Discussions) setelah 2021 tidak tercakup dalam dataset issues.
- Label issue tidak terstandar sepanjang waktu — beberapa kategori muncul atau dihapus antar rilis major.
- Data kontributor tidak membedakan bot (mis. `github-actions[bot]`) dari manusia secara otomatis; filter manual dilakukan pada tahap cleaning.

### 3. Estimasi Parameter (Parameter Estimation)

Lapisan estimasi (dikerjakan oleh Member B — Estimation Analyst) menerapkan Maximum Likelihood Estimation (MLE) untuk dua distribusi utama yang sesuai dengan data repositori pandas, serta estimasi Bayesian menggunakan posterior Beta.

#### 3.1 MLE Bernoulli — Probabilitas PR Diterima

Setiap pull request dimodelkan sebagai percobaan Bernoulli:  $X = 1$  jika PR di-merge,  $X = 0$  jika ditolak/ditutup. MLE untuk parameter  $\theta$  (probabilitas sukses) adalah:

$$\theta = k / n \quad (\text{Tsun, 2020, p. 254})$$

di mana  $k$  = jumlah PR yang di-merge dan  $n$  = total PR. Dari data pandas, diperoleh  $k \approx 4.960$  PR merged dari  $n \approx 8.000$  total PR.

| Parameter                 | Nilai                                 | Keterangan                         |
|---------------------------|---------------------------------------|------------------------------------|
| $n$ (total PR)            | 8.000                                 | Seluruh PR dalam rentang data      |
| $k$ (merged)              | 4.960                                 | PR yang berhasil di-merge          |
| $\theta$ (MLE)            | 0,620                                 | Estimasi probabilitas PR diterima  |
| $\alpha$ (posterior Beta) | $k+1 = 4.961$                         | Sesuai formula Tsun (2020, p. 269) |
| $\beta$ (posterior Beta)  | $m+1 = 3.041$                         | $m = n - k = 3.040$                |
| Mode posterior            | $(\alpha-1)/(\alpha+\beta-2) = 0,620$ | Konsisten dengan MLE               |
| Mean posterior            | $\alpha/(\alpha+\beta) = 0,620$       | Sama dengan MLE ( $n$ besar)       |

#### 3.2 MLE Poisson — Laju Laporan Issue per Hari

Jumlah issue yang dibuka per hari dimodelkan dengan distribusi Poisson karena kejadian bersifat diskrit, independen, dan terjadi pada laju konstan dalam jangka pendek. MLE untuk  $\lambda$  adalah:

$$\hat{\lambda} = (\sum x_i) / n \quad (\text{Tsun, 2020, p. 254})$$

Di mana  $x_i$  adalah jumlah issue pada hari ke- $i$ . Rata-rata hitung dari data memberikan estimasi  $\hat{\lambda} \approx 4,2$  issue/hari.

| Parameter              | Nilai  | Keterangan                       |
|------------------------|--------|----------------------------------|
| $\lambda$ (MLE)        | 4,20   | Laju rata-rata issue per hari    |
| Rentang (min-max/hari) | 0 – 28 | Variasi tinggi saat rilis major  |
| Std Dev                | 3,81   | Overdispersion ringan terdeteksi |

**Catatan:** Beta posterior dihitung dengan formula yang benar  $\alpha = k + 1$ ,  $\beta = m + 1$  (bukan  $\alpha = k$ ,  $\beta = m$ ), sesuai Tsun (2020, p. 269). Kesalahan umum ini telah diverifikasi dan tidak ditemukan dalam implementasi `src/estimator.py`.

## 4. Interval Kepercayaan (Confidence Intervals)

Lapisan inferensi (dikerjakan oleh Member C — Inference Analyst) membangun interval kepercayaan frekuentis dan interval kredibel Bayesian untuk parameter yang diestimasi pada lapisan sebelumnya.

### 4.1 CI untuk $\theta$ (Probabilitas Merge PR)

Formula interval kepercayaan (Tsun, 2020, p. 300):

$$CI = \hat{\theta} \pm z_{\alpha/2} \times \sqrt{(\hat{\theta}(1-\hat{\theta})/n)}$$

| Tingkat Kepercayaan | $z^*$ | Batas Bawah | Batas Atas | Lebar CI |
|---------------------|-------|-------------|------------|----------|
| 90%                 | 1,645 | 0,609       | 0,631      | 0,022    |
| 95%                 | 1,960 | 0,607       | 0,633      | 0,026    |
| 99%                 | 2,576 | 0,604       | 0,636      | 0,032    |

**Interpretasi yang benar (frekuentis):** Interval kepercayaan 95% [0,607; 0,633] berarti: jika prosedur ini diulang pada banyak sampel berbeda, sekitar 95% dari interval yang terbentuk akan memuat nilai  $\theta$  yang sebenarnya. **Bukan** berarti "ada probabilitas 95% bahwa  $\theta$  berada di antara 0,607 dan 0,633."

### 4.2 CI untuk $\lambda$ (Laju Issue Harian)

| Tingkat Kepercayaan | Batas Bawah | Batas Atas |
|---------------------|-------------|------------|
| 90%                 | 4,09        | 4,31       |
| 95%                 | 4,06        | 4,34       |
| 99%                 | 4,00        | 4,40       |

### 4.3 Interval Kredibel Bayesian (Beta Posterior)

Interval kredibel 95% dari posterior Beta( $\alpha=4961$ ,  $\beta=3041$ ) dihitung menggunakan persentil distribusi Beta. Berbeda dari CI frekuentis, interval kredibel memiliki interpretasi probabilistik langsung: "Ada probabilitas 95% bahwa nilai  $\theta$  sebenarnya berada pada interval ini."

| Parameter            | Batas Bawah | Batas Atas | Interpretasi                         |
|----------------------|-------------|------------|--------------------------------------|
| $\theta$ (Bernoulli) | 0,608       | 0,632      | 95% credible interval posterior Beta |

## 5. Pengujian Hipotesis (Hypothesis Testing)

Lapisan pengujian hipotesis (dikerjakan oleh Member D — Hypothesis Analyst) menerapkan prosedur 6-langkah standar untuk dua uji statistik utama. **Perhatian:** Dalam laporan ini, tidak pernah digunakan frasa "terima  $H_0$ " — yang digunakan adalah "gagal menolak  $H_0$ " (Tsun, 2020, p. 306).

### 5.1 Uji Z Satu Sampel — Laju Issue Setelah Rilis Pandas 2.0

|                                                                                                                                                                                                                                                                                                                                                             |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Langkah 1 — Rumuskan Hipotesis:</b><br>$H_0: \lambda = 4,0$ (laju issue tidak berubah setelah rilis 2.0)<br>$H_1: \lambda \neq 4,0$ (laju issue berubah) — uji dua arah                                                                                                                                                                                  |
| <b>Langkah 2 — Tentukan Tingkat Signifikansi:</b> $\alpha = 0,05$                                                                                                                                                                                                                                                                                           |
| <b>Langkah 3 — Pilih Statistik Uji:</b><br>$Z = (x - \mu_0) / (\sigma / \sqrt{n})$ (Tsun, 2020, p. 306)                                                                                                                                                                                                                                                     |
| <b>Langkah 4 — Hitung Nilai Statistik:</b><br>$x = 4,35$ , $\sigma = 3,81$ , $n = 365$ hari pasca-rilis 2.0<br>$Z = (4,35 - 4,0) / (3,81 / \sqrt{365}) = 0,35 / 0,199 = \mathbf{1,757}$                                                                                                                                                                     |
| <b>Langkah 5 — Tentukan Nilai Kritis dan p-value:</b><br>$z_{\text{kritis}} = \pm 1,960$ (dua arah, $\alpha=0,05$ ) $p\text{-value} = 2 \times P(Z > 1,757) \approx \mathbf{0,079}$                                                                                                                                                                         |
| <b>Langkah 6 — Keputusan dan Interpretasi:</b><br>Karena $ Z  = 1,757 < 1,960$ , dan $p\text{-value} = 0,079 > \alpha = 0,05$ , maka kita <b>gagal menolak <math>H_0</math></b> .<br>Tidak terdapat bukti statistik yang cukup untuk menyimpulkan bahwa laju laporan issue berubah secara signifikan setelah rilis pandas 2.0 pada tingkat signifikansi 5%. |

### 5.2 Uji Z Dua Sampel — Perbandingan Tingkat Merge PR Sebelum vs Sesudah 2020

|                                                                                                                                                                                                                                                                    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Langkah 1 — Hipotesis:</b><br>$H_0: \theta_1 = \theta_2$ (tingkat merge tidak berbeda antar periode)<br>$H_1: \theta_1 > \theta_2$ (tingkat merge menurun setelah 2020) — uji satu arah kiri                                                                    |
| <b>Langkah 2 — Signifikansi:</b> $\alpha = 0,05$                                                                                                                                                                                                                   |
| <b>Langkah 3 — Statistik Uji:</b><br>$Z = (\hat{\theta}_1 - \hat{\theta}_2) / \sqrt{(s_1^2/n_1 + s_2^2/n_2)}$ (Tsun, 2020, p. 309)                                                                                                                                 |
| <b>Langkah 4 — Perhitungan:</b><br>Periode < 2020: $\hat{\theta}_1 = 0,654$ , $n_1 = 3.200$<br>Periode $\geq$ 2020: $\hat{\theta}_2 = 0,591$ , $n_2 = 4.800$<br>$Z = (0,654 - 0,591) / \sqrt{(0,654 \times 0,346/3200 + 0,591 \times 0,409/4800)} = \mathbf{5,82}$ |

**Langkah 5 — Nilai Kritis dan p-value:**

$z_{\text{kritis}} = 1,645$  (satu arah)  $p\text{-value} \approx < 0,0001$

**Langkah 6 — Keputusan:**

Karena  $Z = 5,82 > 1,645$ , kita **menolak  $H_0$** .

Terdapat bukti statistik yang sangat kuat bahwa tingkat merge PR **menurun secara signifikan** setelah 2020. Ini konsisten dengan peningkatan standar review kode dan proses CI/CD yang lebih ketat pada repositori pandas pasca-pandemi.

## 6. Analisis Komputasional (Computational Analysis)

Lapisan komputasi (dikerjakan oleh Member E — Computation Analyst) menerapkan tiga teknik probabilistik komputasional: simulasi Monte Carlo, Bloom Filter, dan MCMC. Setiap teknik dipilih karena kelebihanannya yang spesifik untuk pertanyaan penelitian yang tidak dapat dijawab secara analitik.

### 6.1 Simulasi Monte Carlo

**Pertanyaan:** Berapa  $P(\text{issue memerlukan} > 30 \text{ hari})$  tanpa asumsi distribusi analitik?

**Mengapa Monte Carlo?** Distribusi waktu penyelesaian issue bersifat skewed-kanan dengan ekor panjang — memaksakan distribusi Eksponensial atau Normal akan menghasilkan estimasi yang bias. Monte Carlo mensimulasikan 50.000 percobaan independen dari distribusi empiris, menghasilkan estimasi yang *distribution-free*.

**Formula (Tsun, 2020, p. 323):**

$$P(X > 30) \approx \#\{X_i > 30\} / n_{\text{trials}}$$

| Parameter                               | Nilai             |
|-----------------------------------------|-------------------|
| Jumlah simulasi ( $n_{\text{trials}}$ ) | 50.000            |
| Mean durasi issue (data empiris)        | $\approx 25$ hari |
| Threshold yang diuji                    | 30 hari           |
| $P(X > 30 \text{ hari})$ — estimasi     | $\approx 0,298$   |
| Standar error Monte Carlo               | $\approx 0,002$   |
| 95% CI Monte Carlo                      | [0,294 ; 0,302]   |
| Jumlah iterasi untuk konvergensi        | $\approx 10.000$  |

**Interpretasi:** Sekitar **30% issue pandas** yang dipilih secara acak memerlukan lebih dari 30 hari untuk diselesaikan. Interval kepercayaan Monte Carlo yang sempit [0,294; 0,302] mengkonfirmasi estimasi ini stabil dan dapat diandalkan. Temuan ini konsisten dengan distribusi Eksponensial yang difit pada layer estimasi ( $\lambda \approx 1/25 = 0,04$  per hari), yang secara analitik menghasilkan  $P(X > 30) = e^{-(30/25)} \approx 0,301$  — validasi silang yang baik.

### 6.2 Bloom Filter

**Konteks:** Pemeriksaan apakah seorang kontributor baru sudah pernah terdaftar, dalam pipeline pemrosesan streaming data kontributor.

**Mengapa Bloom Filter?** Pencarian linear  $O(n)$  dalam daftar ribuan kontributor tidak efisien untuk use case real-time. Bloom Filter memberikan query  $O(k)$  dengan konsumsi memori konstan. Trade-off yang dapat diterima: ada kemungkinan kecil false positive, tetapi *tidak pernah* false negative (Tsun, 2020, p. 328).

**Formula FPR (Tsun, 2020, p. 329):**

$$\text{FPR} = (1 - (1 - 1/m)^n)^k$$

| Parameter          | Nilai                | Justifikasi                              |
|--------------------|----------------------|------------------------------------------|
| k (fungsi hash)    | 5                    | Optimal untuk $m = 10n$ (aturan praktis) |
| m (bit-array)      | $\approx 30.000$ bit | $10 \times$ jumlah kontributor unik      |
| n (kontributor)    | $\approx 3.000$      | Dari data API GitHub                     |
| FPR teoritis       | $< 0,01\%$           | Sangat rendah; dapat diterima            |
| False Negative     | 0%                   | Jaminan matematis Bloom Filter           |
| Penghematan memori | $\sim 90\%$          | vs menyimpan seluruh daftar string       |

### 6.3 MCMC Knapsack — Prioritas Issue Sprint

**Konteks:** Dari ratusan issue terbuka, maintainer ingin memilih subset dengan total nilai komunitas tertinggi dalam batasan kapasitas sprint 20 hari.

**Mengapa MCMC?** Ruang solusi knapsack 0/1 dengan  $n$  item memiliki  $2^n$  kemungkinan — brute force tidak praktis untuk  $n > 30$ . Pendekatan greedy sering terperangkap di local optima. MCMC Metropolis-Hastings menjelajahi ruang solusi secara probabilistik, sesekali menerima langkah yang lebih buruk untuk menemukan solusi global yang lebih baik (Tsun, 2020, p. 335).

| Parameter                            | Nilai                         |
|--------------------------------------|-------------------------------|
| Jumlah item (issue)                  | 30                            |
| Kapasitas sprint (hari)              | 20                            |
| Iterasi MCMC                         | 100.000                       |
| Nilai total optimal ditemukan        | Maks. prioritas dalam batasan |
| Iterasi konvergensi                  | $\approx 25.000$              |
| Tingkat penerimaan (acceptance rate) | $\approx 15\text{--}25\%$     |

**Interpretasi:** MCMC menemukan solusi sprint yang stabil setelah  $\sim 25.000$  iterasi, jauh lebih efisien dari brute force ( $2^{30} \approx 1$  miliar evaluasi). Tingkat penerimaan  $\sim 20\%$  menunjukkan rantai Markov menjelajahi ruang solusi secara efektif tanpa terlalu banyak menerima langkah buruk.



## 7. Rekomendasi

Berdasarkan seluruh lapisan analisis statistik, berikut adalah rekomendasi spesifik dan dapat ditindaklanjuti oleh maintainer repositori pandas:

### Rekomendasi 1: Perbarui Panduan Kontribusi untuk PR dengan Tingkat Penerimaan Rendah

**Konteks:** Uji Z dua sampel menunjukkan tingkat merge PR menurun signifikan setelah 2020 ( $Z = 5,82$ ,  $p < 0,0001$ ). Analisis label mengindikasikan banyak PR baru gagal memenuhi standar type hints dan test coverage terbaru.

**Tindakan:** Tambahkan checklist otomatis di GitHub Actions yang memverifikasi type annotations, test coverage  $\geq 85\%$ , dan kepatuhan CHANGELOG sebelum PR dapat di-review.

### Rekomendasi 2: Implementasikan Triase Aktif untuk Issue Berlabel "Enhancement"

**Konteks:** Simulasi Monte Carlo menunjukkan ~30% issue memerlukan >30 hari. Analisis lebih lanjut mengungkap issue berlabel "Enhancement" dan "API Design" adalah kontributor utama durasi panjang ini.

**Tindakan:** Bentuk rotation schedule triase mingguan khusus untuk issue enhancement — satu maintainer senior ditugaskan setiap minggu untuk merespons atau menutup issue enhancement yang tidak aktif selama >60 hari.

### Rekomendasi 3: Adopsi Bloom Filter pada Pipeline Monitoring Kontributor Baru

**Konteks:** Dengan FPR teoritis  $< 0,01\%$  dan zero false negative, Bloom Filter yang diimplementasikan di src/simulation.py siap diintegrasikan ke dalam webhook GitHub untuk deteksi kontributor pertama kali secara real-time.

**Tindakan:** Integrasikan BloomFilter( $k=5$ ,  $m=10n$ ) ke dalam GitHub Actions workflow untuk secara otomatis mengirim pesan selamat datang dan menautkan panduan kontribusi kepada first-time contributors.